



Ανάλυση συναισθήματος σε κριτικές ταινιών

Γιώργος Μοσχόβης (geomos@athenarc.gr)

Ομάδα Πανελληνίου Διαγωνισμού Τεχνητής Νοημοσύνης
Αρχιμήδης, Ερευνητικό Κέντρο «Αθηνά»





Περιεχόμενα

- Τί είναι η ανάλυση συναισθήματος;
- Αυτόματη ανάλυση συναισθήματος με χρήση αλγορίθμων μηχανικής μάθησης



Περιεχόμενα

- Τι είναι η ανάλυση συναισθήματος;
- Αυτόματη ανάλυση συναισθήματος με χρήση αλγορίθμων μηχανικής μάθησης
 - Λογιστική παλινδρόμηση με δυαδικά διανύσματα

Ανάλυση συναισθήματος

- Εξαγωγή Υποκειμενικής Πληροφορίας από Κείμενο (π.χ. κριτικές ταινιών)

Είσοδος	Έξοδος
"Η ταινία ήταν συναρπαστική!"	1 (Θετική γνώμη)
"Βαρέθηκα μετά από 5'..."	0 (Αρνητική γνώμη)

- Τι βήματα πρέπει να ακολουθήσουμε;
 - Μετατροπή του κειμένου σε μορφή κατανοητή για τον υπολογιστή → **αριθμητική αναπαράσταση!**
 - Εφαρμογή αλγορίθμου κατηγοριοποίησης



Ανάλυση συναισθήματος

- Υπάρχουν πολλοί τρόποι με τους οποίους μπορούμε να μετατρέψουμε την κάθε κριτική σε διάνυσμα αριθμών...
 - π.χ. **Bag-of-Words**, TF-IDF, Word2Vec...
- Υπάρχουν επίσης πολλοί αλγόριθμοι με τους οποίους μπορούμε να κατηγοριοποιήσουμε τις κριτικές με βάση το συναίσθημα...
 - π.χ. **Λογιστική παλινδρόμηση**, αφελής ταξινομητής Bayes, νευρωνικά δίκτυα...



Βασικά Στάδια Υλοποίησης

- **Προ-επεξεργασία:**
 - Αφαίρεση θορύβου (HTML tags), tokenization, αφαίρεση stopwords.
- **Διανυσματοποίηση (Vectorization):**
 - Μετατροπή κειμένων σε διανύσματα (αριθμούς).
- **Μοντελοποίηση** με χρήση μηχανικής μάθησης:
 - Εκπαίδευση αλγορίθμων κατηγοριοποίησης.

Κάθε φορά τα βήματα θα είναι **τα ίδια!**



Η συλλογή κριτικών IMDb

- Μια συλλογή από 50.000 κριτικές ταινιών με έντονη πολικότητα (θετικές/αρνητικές) από το **I**nternet **M**ovie **D**atabase (IMDb).
- Χρησιμοποιείται για Ανάλυση Συναισθήματος (Sentiment Analysis) και ως μέτρο σύγκρισης (benchmark) αλγορίθμων στην Επεξεργασία Φυσικής Γλώσσας (ΕΦΓ).
- Δημιουργήθηκε από ερευνητές του εργαστηρίου TN του Stanford (2011).



Η συλλογή κριτικών IMDb

- **Συνολικό Μέγεθος:** 50.000 Κριτικές.
- **Ισορροπημένος Διαχωρισμός:**
 - **Σύνολο Εκπαίδευσης (Training Set):** 25.000 κριτικές (12,5χιλ Θετικές, 12,5χιλ Αρνητικές).
 - **Σύνολο Ελέγχου (Test Set):** 25.000 κριτικές (12,5χιλ Θετικές, 12,5χιλ Αρνητικές).
- **Λεξιλόγιο:** Όλες οι κριτικές περιέχουν περίπου 88.000 μοναδικές λέξεις και συχνά θόρυβο που απαιτεί προ-επεξεργασία.

Η μέθοδος bag-of-words

- Κάθε κριτική είναι σαν ένας «σάκος από λέξεις»
 - Μας ενδιαφέρει **ποιες λέξεις εμφανίζονται πιο συχνά** στις θετικές κριτικές (π.χ. «φανταστική», «υπέροχη», ...) και **ποιες σπάνια ή καθόλου**. Αντίστοιχα για τις αρνητικές κριτικές.
 - **Δεν** μας νοιάζει **πόσες φορές εμφανίζεται** μια λέξη (αρκεί να εμφανίζεται τουλάχιστον μια φορά για να την λάβουμε υπόψη).
- Ασχολούμαστε μόνο με λέξεις που εμφανίζονται τουλάχιστον κάποιες φορές.

Η μέθοδος bag-of-words

- Για κάθε κριτική φτιάχνουμε ένα πολύ μεγάλο διάνυσμα (όσο και οι λέξεις που έχουν απομείνει μετά την προεπεξεργασία)...
 - Κάθε θέση του $1 \leq i \leq |V|$ αντιστοιχεί σε μια λέξη.
 - Βάζουμε **1 αν υπάρχει** η λέξη της i -οστής θέσης στην κριτική και **0 αν δεν υπάρχει**.
- Τώρα έχουμε μια αριθμητική αναπαράσταση για κάθε κριτική! Μπορούμε **να εκπαιδεύσουμε** τον αλγόριθμο της λογιστικής παλινδρόμησης.