

Γραμμικά μοντέλα μηχανικής μάθησης

Γραμμικά μοντέλα για παλινδρόμηση και κατηγοριοποίηση

Γιώργος Μοσχόβης, Οργανωτική επιτροπή ΠΔΤΝ
geomos@athenarc.gr




<http://www.ptdn.gr>

Πιθανοτική γραμμική παλινδρόμηση

Μοντέλο: Υποθέτουμε μια γραμμική σχέση

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1x_1 + w_2x_2 + \dots + w_Dx_D$$



- συνάρτηση κόστους;


Εκπαίδευση με μέγιστη πιθανόφανεia

Μεγιστοποίηση ως προς $\mathbf{w}$ ισοδυναμεί με ελαχιστοποίηση της συνάρτησης ελαχίστων τετραγώνων


$$\frac{1}{2} \sum_{n=1}^N (t_n - y(x_n, \mathbf{w}))^2$$

Εκπαίδευση με μέγιστη πιθανόφανεια

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N (t_n - y(\mathbf{x}_n, \mathbf{w}))^2$$




Μέγιστη πιθανοφάνεια



Η κεντρική **μπλε** γραμμή δείχνει την $b_0 + b_1x$, ενώ οι δύο **κόκκινες** γραμμές βρίσκονται σε απόσταση μιας τυπικής απόκλισης (δηλ. σ) από την μπλε γραμμή

Οι τιμές (b_0, b_1) δεν έχουν επιλεγεί σωστά (η γραμμή δεν έχει «ταιριιάξει» στα δεδομένα) για αυτό και η **λογαριθμική πιθανοφάνεια** είναι μικρή $\mathcal{L} = -736.2031$


Μέγιστη πιθανοφάνεια



Η κεντρική **μπλε** γραμμή δείχνει την $b_0 + b_1x$, ενώ οι δύο **κόκκινες** βρίσκονται σε απόσταση μιας τυπικής απόκλισης

Οι τιμές (b_0, b_1) έχου επιλεγεί βέλτιστα, αλλά η διακύμανση σ^2 του σφάλματος ή θορύβου δεν είναι βέλτιστη (οι κόκκινες γραμμές της τυπικής απόκλισης δεν ταιριάζουν στα δεδομένα). Η **πιθανοφάνεια** είναι $\mathcal{L} = -41.2290$


Μέγιστη πιθανοφάνεια



Η κεντρική **μπλε** γραμμή δείχνει την $b_0 + b_1x$, ενώ οι δύο **κόκκινες** βρίσκονται σε απόσταση μιας τυπικής απόκλισης


Οι τιμές (b_0, b_1, σ^2) είναι όλες βέλτιστες. Η **λογαριθμική πιθανοφάνεια** είναι η μέγιστη $\mathcal{L} = -6.1644$

Μη γραμμική παλινδρόμηση



Έστω τα δεδομένα του Σχήματος


Μη γραμμική παλινδρόμηση



Γραμμική παλινδρόμηση $y = b_0 + b_1x + \epsilon$

Δεν ταιριάζει καλά στα δεδομένα!


Μη γραμμική παλινδρόμηση



Παλινδρόμηση με 2-τάξης πολυώνυμο

$$y = b_0 + b_1x + b_2x^2 + \epsilon$$


Μη γραμμική παλινδρόμηση



Παλινδρόμηση με 3-τάξης πολυώνυμο

$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + \epsilon$$

Μη γραμμική παλινδρόμηση



Παλινδρόμηση με 4-τάξης πολυώνυμο

$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + b_4x^4 + \epsilon$$


Μη γραμμική παλινδρόμηση

Στην πράξη τα πολυώνυμα δεν είναι καλός τρόπος μοντελοποίησης προβλημάτων μη γραμμικής παλινδρόμησης. Αυτό συμβαίνει διότι ο αριθμός των παραμέτρων τους αυξάνει εκθετικά με τη διάσταση D του δεδομένου εισόδου $\mathbf{x}_i = (x_{i,1}, \dots, x_{i,D})$ (στο προηγούμενο παράδειγμα $D = 1!$)

Υπάρχουν πολύ καλύτερα μοντέλα μη γραμμικής παλινδρόμησης η παρουσίαση των οποίων είναι εκτός του σκοπού του μαθήματος


- $\Rightarrow$ αναλύονται σε μαθήματα υπολογιστικής στατιστικής και μηχανικής μάθησης

Παλινδρόμηση




Δεδομένα τιμών ενοικίου διαμερισμάτων σε σχέση με το μέγεθος σε τετραγωνικά μέτρα

Παλινδρόμηση




Πώς θα μπορούσαμε να προβλέψουμε την τιμή του ενοικίου για ένα διαμέρισμα με $54m^2$ (μπλε κουκκίδα);

Παλινδρόμηση




θα μπορούσαμε να ταιριάξουμε μια ευθεία γραμμή στα αρχικά δεδομένα $\Rightarrow$ γραμμική παλινδρόμηση

Παλινδρόμηση




και έπειτα να κάνουμε προβλέψεις με βάση την γραμμή που βρήκαμε

Παλινδρόμηση



θα μπορούσαμε να ταιριάξουμε και μη γραμμικές συνάρτησεις
⇒ μη γραμμική παλινδρόμηση
που δίνουν διαφορετικές προβλέψεις


Παλινδρόμηση



Σε κάθε περίπτωση αυτό που προβλέπουμε παίρνει συνεχείς τιμές


- Αν θα θέλαμε να προβλέπουμε διακριτές τιμές τι είδους στατιστικό μοντέλο θα χρειαζόμασταν;

Κατηγοριοποίηση




Έστω δεδομένα ασθενών ώστε στον οριζόντιο άξονα (δεδομένα εισόδου) δίνεται το μέγεθος ενός «ενδεχομένως» καρκινικού όγκου και στο κάθετο άξονα έχουμε δύο τιμές 0 ή 1 (δεδομένα εξόδου) για τις δύο περιπτώσεις, δηλ. καλοήθης ή κακοήθης

Κατηγοριοποίηση



Κάθε δεδομένο ανήκει σε μια κατηγορία, δηλ στην κατηγορία 0 ή την κατηγορία 1 (δηλ. κάθε $y_i \in \{0, 1\}$)

Κατηγοριοποίηση



Πρόβλημα στατιστικής πρόβλεψης: Για ένα νέο όγκο (+ στο σχήμα) πως μπορούμε να εκτιμήσουμε την πιθανότητα να είναι καλοήθης ή κακοήθης;


Κατηγοριοποίηση



Το πρόβλημα αυτό ονομάζεται **κατηγοριοποίηση** δεδομένων


- Τα δεδομένα εξόδου παίρνουν ένα διακριτό σύνολο τιμών
- δηλ. έχουμε ένα σύνολο δυνατών κατηγοριών

Κατηγοριοποίηση



Τα δεδομένα εισόδου θα μπορούσε να είναι δισδιάστατα

Κατηγοριοποίηση



ή πολυδιάστατα

(όπως στο παράδειγμα που θα θέλαμε να κατηγοριοποιούμε
εικόνες ανάλογα με το φύλο)

Κατηγοριοποίηση

7	2	1	0	4	1	4	9	5	9
0	6	9	0	1	5	9	7	3	4
9	6	6	5	4	0	7	4	0	1
3	1	3	4	7	2	7	1	2	1
1	7	4	2	3	5	1	2	4	4
6	3	5	5	6	0	4	1	9	5
7	8	9	3	7	4	6	4	3	0
7	0	2	9	1	7	3	2	9	7
7	6	2	7	8	4	7	3	6	1
3	6	9	3	1	4	1	7	6	9

Στην πιο γενική περίπτωση τα δεδομένα είναι πολυδιάστατα και έχουμε πολλές κατηγορίες

(όπως στο παράδειγμα που θα θέλαμε να κατηγοριοποιούμε εικόνες σε ένα από τα 10 αριθμητικά ψηφία)

Κατηγοριοποίηση



Πρόβλημα στατιστικής πρόβλεψης: Για ένα νέο όγκο πως μπορούμε να εκτιμήσουμε την πιθανότητα να είναι καλοήθης ή κακοήθης;

Χρειαζόμαστε ένα μοντέλο που να εκτιμά την πιθανότητα να είναι κακοήθης (δηλ. την πιθανότητα του ενδεχομένου $y = 1$ δοθέντος του x)

$$p(y = 1|x) \quad \text{όπου } x = \text{'size of tumour'}$$

Κατηγοριοποίηση



$$p(y = 1|x) \quad \text{όπου } x = \text{'size of tumour'}$$

Προφανώς η πιθανότητα να έχουμε καλοήγη όγκο είναι

$$p(y = 0|x) = 1 - p(y = 1|x)$$

(οπότε χρειάζεται να μοντελοποιήσουμε μόνο την $p(y = 1|x)$!)

Γραμμική λογιστική παλινδρόμηση

Αφού $p(y = 1|x)$ είναι μια πιθανότητα, δηλ. $p(y = 1|x) \in [0, 1]$, αν εισάγουμε ένα μοντέλο $p(y = 1|x, \beta)$ με παραμέτρους β θα πρέπει να ικανοποιεί

$$p(y = 1|x, \beta) \in [0, 1]$$

Αυτό μπορεί να επιτευχθεί χρησιμοποιώντας μια συνάρτηση $f(x, \beta)$ (link function) που παίρνει συνεχή τιμές, π.χ.


$$f(x, \beta) = \beta_0 + \beta_1 x, \quad \beta = (\beta_0, \beta_1)$$

την οποία περνάμε μέσα από τη σιγμοειδή (ονομάζεται και **λογιστική συνάρτηση**)

$$p(y = 1|x, \theta) = \frac{1}{1 + e^{-f(x, \beta)}} = \frac{1}{1 + e^{-\beta_0 - \beta_1 x}}$$

(Το μοντέλο ονομάζεται γραμμική λογιστική παλινδρόμηση λόγω ότι η συνάρτηση που μπαίνει ως είσοδο στην σιγμοειδή είναι γραμμική!)

Γραμμική λογιστική παλινδρόμηση



Σιγμοειδής συνάρτηση

$$\frac{1}{1 + e^{-z}}, \quad z \in \mathbb{R}$$

- Παίρνει τιμές από μηδέν έως 1
- Όταν $z = 0$ ισούται με 0.5
- Όταν $z < 0$ η τιμή της είναι μικρότερη του 0.5
- Όταν $z > 0$ η τιμή της είναι μεγαλύτερη του 0.5

Γραμμική λογιστική παλινδρόμηση

$$p(y = 1|x, \beta) = \frac{1}{1 + e^{-\beta_0 - \beta_1 x}} = \begin{cases} > 0.5 & \beta_0 + \beta_1 x > 0 \\ = 0.5 & \beta_0 + \beta_1 x = 0 \\ < 0.5 & \beta_0 + \beta_1 x < 0 \end{cases}$$

- Το **σύνορο απόφασης** (decision boundary) ορίζεται ως το x για το οποίο οι δύο κατηγορίες είναι ισοπίθανες, δηλ.

$$p(y = 1|x, \beta) = p(y = 0|x, \theta) = 0.5 \Rightarrow$$

$$\beta_0 + \beta_1 x = 0 \Rightarrow x = -\frac{\beta_0}{\beta_1}$$

- Όταν το δεδομένο εισόδου είναι διάνυσμα, δηλ. $\mathbf{x} = (x_1, \dots, x_D)$

$$p(y = 1|\mathbf{x}, \beta) = \frac{1}{1 + e^{-\beta_0 - \sum_{i=1}^D \beta_i x_i}}$$

και σύνορο απόφασης είναι όλα τα $\mathbf{x}$ για τα οποία

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_D x_D = 0$$

(γραμμή για $D = 2$, επιφάνεια για $D = 3 \dots$ κτλ)

Γραμμική λογιστική παλινδρόμηση

Έστω ότι γνωρίζουμε τις τιμές των παραμέτρων

$\theta = (\beta_0, \beta_1, \beta_2, \dots, \beta_D)$ (το πως τις εκτιμούμε θα το δούμε σε λίγο)

Στην πράξη θα χρησιμοποιούμε το μοντέλο μας ως εξής. Για οποιοδήποτε δεδομένο x_* θα **προβλέπουμε/αποφασίζουμε** την άγνωστη κατηγορία $y_* \in \{0, 1\}$ βάσει


$$\begin{aligned} p(y = 1|x, \beta) &\geq 0.5 &\Rightarrow y_* = 1 \\ p(y = 1|x, \beta) &< 0.5 &\Rightarrow y_* = 0 \end{aligned}$$

ή ισοδύναμα

$$\begin{aligned} \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_D x_D &\geq 0 &\Rightarrow y_* = 1 \\ \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_D x_D &< 0 &\Rightarrow y_* = 0 \end{aligned}$$

(Οπότε το σύνορο απόφασης $\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_D x_D = 0$ είναι ουσιαστικά εκεί που η απόφαση μας αλλάζει!)

Γραμμική λογιστική παλινδρόμηση



Η μαύρη γραμμή είναι το σύνορο απόφασης

Κάθε δεδομένο εισόδου $\mathbf{x} = (x_1, x_2)$ που βρίσκεται πάνω από τη διαχωριστική γραμμή θα κατηγοριοποιηθεί στην κατηγορία 1.
Αν είναι κάτω από την γραμμή θα κατηγοριοποιηθεί στην 0

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια

Εκτιμούμε τις άγνωστες παραμέτρους μεγιστοποιώντας την λογαριθμική πιθανοφάνεια


$$\mathcal{L}(\beta) = \sum_{i=1}^n y_i \log \sigma(\beta^T \mathbf{x}_i) + (1 - y_i) \log (1 - \sigma(\beta^T \mathbf{x}_i))$$

Η μεγιστοποίηση δεν μπορεί να γίνει αναλυτικά

Θα πρέπει να χρησιμοποιήσουμε **αριθμητική βελτιστοποίηση**

Ωστόσο η $\mathcal{L}(\beta_0, \beta)$ είναι κοίλη (στρέφει τα κοιλά προς τα κάτω),
οπότε η αριθμητική βελτιστοποίηση μπορεί να βρεί το ολικό
μέγιστο

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Η $\mathcal{L}(\beta)$ είναι κοίλη συνάρτηση

Οπότε μπορούμε να βρούμε το ολικό μέγιστο εφαρμόζοντας μια μέθοδο όπως αυτή της ανοδικής κλίσης (gradient ascent)

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια

- Παίρνουμε μερικές παραγώγους

$$\frac{\partial \mathcal{L}(\boldsymbol{\beta})}{\beta_d} = \sum_{i=1}^n \left(y_i - \sigma(\boldsymbol{\beta}^T \mathbf{x}_i) \right) x_{i,d}, \quad d = 0, \dots, D$$

- Διάνυσμα μερικών παραγώγων

$$\nabla_{\mathcal{L}(\boldsymbol{\beta})} = \begin{bmatrix} \frac{\partial \mathcal{L}(\boldsymbol{\beta})}{\beta_0} \\ \frac{\partial \mathcal{L}(\boldsymbol{\beta})}{\beta_1} \\ \dots \\ \frac{\partial \mathcal{L}(\boldsymbol{\beta})}{\beta_D} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n \left(y_i - \sigma(\boldsymbol{\beta}^T \mathbf{x}_i) \right) x_{i,0} \\ \sum_{i=1}^n \left(y_i - \sigma(\boldsymbol{\beta}^T \mathbf{x}_i) \right) x_{i,1} \\ \dots \\ \sum_{i=1}^n \left(y_i - \sigma(\boldsymbol{\beta}^T \mathbf{x}_i) \right) x_{i,D} \end{bmatrix}$$

Αλγόριθμος ανοδικής κλίσης

① Αρχικοποίηση: $t = 1$, $(\beta^{(1)})$, $\eta > 0$.

② Ενημέρωση παραμέτρων

$$\beta^{(t+1)} = \beta^{(t)} + \eta \nabla_{\mathcal{L}(\beta^{(t)})}$$


③ $t = t + 1$ και πήγαινε στο βήμα 2, ή τερμάτισε

Διαισθητικά ο αλγοριθμός υλοποιεί μια συγκεκριμένη στρατηγική για ανέβασμα σε λόφο (hill climbing)

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια

Ας δούμε κάποια παραδείγματα εφαρμογής του αλγορίθμου


Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Έχουμε δισδιάστατα δεδομένα εισόδου, δηλ. κάθε $\mathbf{x}_i = (x_{i,1}, x_{i,2})$

Κόκκινες κουκίδες αντιστοιχούν σε δεδομένα της κατηγορίας 1
ενώ **μπλε** κουκίδες αντιστοιχούν σε δεδομένα της κατηγορίας 0


Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Σχήμα: Η γραμμή $p = 0.5$ αντιστοιχεί στο σύνоро απόφασης $\sigma(\beta_0 + \beta_1 x_1 + \beta_2 x_2) = 0.5 \Rightarrow \beta_0 + \beta_1 x_1 + \beta_2 x_2 = 0$. Ομοίως οι γραμμές $p = 0.9$ και $p = 0.1$ αντιστοιχούν σε $\sigma(\beta_0 + \beta_1 x_1 + \beta_2 x_2) = 0.9$ και $\sigma(\beta_0 + \beta_1 x_1 + \beta_2 x_2) = 0.1$.


Αρχικοποίηση ($t = 1$) του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια




Επανάληψη $t = 10$ του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια




Επανάληψη $t = 20$ του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια




Επανάληψη $t = 50$ του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Επανάληψη $t = 300$ του αλγορίθμου της ανοδικής κλίσης


Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Έχουμε τρισδιάστατα δεδομένα εισόδου, δηλ. κάθε
 $\mathbf{x}_i = (x_{i,1}, x_{i,2}, x_{i,3})$

Κόκκινες κουκίδες αντιστοιχούν σε δεδομένα της κατηγορίας 1
ενώ **μπλε** κουκίδες αντιστοιχούν σε δεδομένα της κατηγορίας 0


Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Σχήμα: Η επιφάνεια αντιστοιχεί στο σύνορο απόφασης
 $\sigma(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3) = 0.5 \Rightarrow \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 = 0.$


Αρχικοποίηση ($t = 1$) του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια




Επανάληψη $t = 20$ του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Επανάληψη $t = 50$ του αλγορίθμου της ανοδικής κλίσης

Εκτίμηση των παραμέτρων με μέγιστη πιθανοφάνεια



Επανάληψη $t = 300$ του αλγορίθμου της ανοδικής κλίσης

Αδυναμίες της λογιστικής παλινδρόμησης

Ένα επιπλέον πρόβλημα με την λογιστική παλινδρόμηση είναι ότι πάντα κατηγοριοποιεί το x_* σε μια εκ των δύο (ή $K...$ στην γενίκευση του μοντέλου) κατηγοριών

- χωρίς ποτέ να μπορεί να αντιληφθεί ότι ίσως το x_* δεν ανήκει σε καμιά από αυτές τις κατηγορίες
- δηλ. ότι το x_* είναι ένα ακραίο δεδομένο και θα πρέπει να κατηγοριοποιηθεί ως άγνωστο


Ως παράδειγμα φαντάσου ότι έχουμε εκπαιδεύσει με μέγιστη πιθανοφάνεια το μοντέλο της λογιστικής παλινδρόμησης για το διαχωρισμό εικόνων που δείχνουν χειρόγραφους αριθμούς είτε του ψηφίου 0 είτε το ψηφίου 1

- Αν κατά την κατηγοριοποίηση άγνωστων εικόνων δώσουμε στο σύστημα μια εικόνα που δείχνει ένα διαφορετικό ψηφίο, π.χ. μια εικόνα του 4
- $\Rightarrow$ τότε το σύστημα θα αποκριθεί 0 ή 1!

Πώς μπορούμε να γενικεύσουμε την μεθοδολογία για περισσότερες από δύο κατηγορίες;

- Έστω ότι έχουμε ζεύγη δεδομένων (x_i, y_i) όπου τώρα το δεδομένο εξόδου $y_i \in \{1, \dots, K\}$ καθορίζει την κατηγορία του x_i από ένα σύνολο $K > 2$ δυνατών κατηγοριών

Πολλές κατηγορίες



Σύνορα απόφασης για 5 κατηγορίας στο δισδιάστατο χώρο δεδομένων εισόδου (το μοντέλο που έχει χρησιμοποιηθεί είναι μη γραμμικό)