



Feature Engineering & Competition Problems

Δημήτρης Τούλης

Data Preprocessing

- Τα δεδομένα που έχουμε δεν είναι πάντα καλής ποιότητας (ακόμα και σε διαγωνισμούς)
- Μπορεί να έχουμε κενές τιμές, λάθος τιμές και άλλα
- Πρέπει να τα διαχειριστούμε κάπως γιατί “Garbage in, garbage out”

Filtering

- Μπορούμε, πολύ απλά, να πετάξουμε τα δεδομένα που έχουν προβλήματα
- Χάνουμε κάποια δεδομένα αλλά είναι καλύτερο από λάθος δεδομένα
- Το πιο συχνό σε διαγωνισμούς

Imputation

- Κάποιες άλλες φορές, αν απλώς διαγράψουμε κάθε γραμμή που της λείπει έστω και μία τιμή, κινδυνεύουμε να χάσουμε τεράστιο μέρος του dataset μας.
- Αν γεμίσουμε τα κενά με λάθος τρόπο, θα εισάγουμε θόρυβο (bias) στο μοντέλο μας και οι προβλέψεις του θα είναι ανακριβείς. Εξετάζουμε γιατί λείπουν τα δεδομένα πριν επιλέξουμε μέθοδο!

Imputation

- Mean / Median Imputation

Γεμίζει τα κενά με τον μέσο όρο ή τη διάμεσο της συγκεκριμένης στήλης.

Για συνεχή αριθμητικά δεδομένα (π.χ. Ύψος, Μισθός). Η διάμεσος προτιμάται αν υπάρχουν outliers.

Imputation

- Mode Imputation

Χρησιμοποιεί την πιο συχνή τιμή (επικρατούσα τιμή).

Για κατηγορικά δεδομένα (π.χ. Χρώμα αυτοκινήτου, Πόλη διαμονής)

Imputation

- Constant Imputation

Αντικαθιστά τα κενά με μια standard τιμή, π.χ. 0 ή "Unknown".

Όταν η ίδια η απουσία της τιμής έχει κάποια σημασία που θέλουμε να καταγράψει το μοντέλο.

Imputation

- Κάτι συγκεκριμένο για το πρόβλημα

Μπορεί να υπάρχει κάποια συμμετρία ή κάποιος άλλος τρόπος να γεμίσουμε τα δεδομένα που να έχει περισσότερο νόημα.

π.χ 2^{ος} ΠΔΤΝ Πρόβλημα 3 :-)

Questions?

Γρήγορες Ερωτήσεις Κατανόησης

Όνομα	Ηλικία	Επάγγελμα	Χρόνος για 100m τρέξιμο
Bob	30	Καθηγητής	15.07
Alex	17	null	13.56
Alice	60	Οδοντίατρος	null
Usain Bolt	22	Αθλητής	9.58
null	null	Αθλητής	11.23

- Διαλέξτε μεθόδους και διαχειριστείτε αυτά τα δεδομένα (Υποθέστε ότι έχετε περισσότερα δεδομένα από αυτά)
- Σε ένα dataset νοσοκομείου λείπει το heart_rate_in_stress_test στο 30% των ασθενών. Προβλέπουμε αν θα καταφέρει το χειρουργείο. Να βάλουμε τον μέσο όρο;

Imputation for Sequences

Imputation for Sequences

- Forward Fill

Παίρνουμε την τελευταία γνωστή τιμή πριν από το κενό και την επαναλαμβάνουμε μέχρι να βρούμε μια νέα τιμή.

Imputation for Sequences

- Backward Fill

Το ακριβώς αντίθετο. Κοιτάμε μπροστά, βρίσκουμε την επόμενη έγκυρη τιμή και τη γεμίζουμε προς τα πίσω.

Imputation for Sequences

- Linear Interpolation

“Σχεδιάζουμε” μια ευθεία γραμμή ανάμεσα στο σημείο πριν το κενό και το σημείο μετά το κενό, και υπολογίζουμε τις ενδιάμεσες τιμές.

Είναι από τις πιο καλές μεθόδους για ομαλές μεταβολές (π.χ. θερμοκρασία, πίεση).

Imputation for Sequences

- Moving Average

Αντί για τον γενικό μέσο όρο, παίρνουμε τον μέσο όρο ενός τοπικού window (π.χ. των 3 προηγούμενων και 3 επόμενων ημερών) για να γεμίσουμε το κενό.

Imputation for Sequences

Στις χρονοσειρές, μπορεί να έχουμε το Data Leakage!

Το Backward Fill και το Interpolation χρησιμοποιεί μελλοντικές τιμές. Για ένα μοντέλο που πρέπει να προβλέψει το μέλλον, υπάρχει ένα προφανές πρόβλημα

Padding

Padding είναι η διαδικασία κατά την οποία προσθέτουμε ένα ειδικό στοιχείο-placeholder στις πιο μικρές ακολουθίες ενός batch, έτσι ώστε όλες οι ακολουθίες να αποκτήσουν το ίδιο μήκος με τη μεγαλύτερη ακολουθία του batch.

Pre-padding

- Pre-padding: Τα μηδενικά μπαίνουν στην αρχή της ακολουθίας. πχ:
 - [0, 0, 0, 42, 17, 89]

Χρήσιμο όταν προβλέπουμε την επόμενη τιμή

Post-padding

- Post-padding: Τα μηδενικά μπαίνουν στο τέλος της ακολουθίας. πχ:
 - [42, 17, 89, 0, 0, 0]

Χρήσιμο όταν έχουμε κείμενο

Scaling

- Το Scaling αλλάζει το εύρος (range) των τιμών των δεδομένων, χωρίς όμως να αλλάζει το σχήμα της κατανομής τους.
- Πολλά μοντέλα υπολογίζουν την Ευκλείδεια απόσταση μεταξύ των δεδομένων.
 - Αν έχετε ένα χαρακτηριστικό όπως το Εισόδημα (π.χ. από 10.000€ έως 100.000€) και ένα χαρακτηριστικό όπως η Ηλικία (π.χ. από 18 έως 80 έτη), το μοντέλο θα θεωρήσει το Εισόδημα πολύ πιο σημαντικό, επειδή συνεισφέρει περισσότερο στην απόσταση

Min-Max Scaling

- Μετατρέπει όλες τις τιμές ώστε να βρίσκονται ανάμεσα στο 0 και το 1

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Standardization

- Μετατοπίζει τα δεδομένα ώστε να έχουν μέση τιμή (mean) ίση με 0 και τυπική απόκλιση (standard deviation) ίση με 1

$$x' = \frac{x - \mu}{\sigma}$$

- Ξεχωριστός υπολογισμός μ, σ για train και test δεδομένα

Questions?

Γρήγορες Ερωτήσεις Κατανόησης

- Για ένα κενό, το linear interpolation με τι είναι ισοδύναμο;
- Για περισσότερα κενά ισχύει;
- Impute (αξιολόγηση υγείας από ζάχαρο στο αίμα):
[1,3,6,9,null,15,17,17,18,18,18,19,null,20,20]
- Impute (πρόβλεψη τιμής μετοχής):
[1,3,6,9,null,15,17,17,18,18,18,19,null,20,20]
- Pad: [[3,4],[6],[1,5,4]]

Data Preprocessing: Done
Break

Questions?

Feature Engineering

- Πολύ δημιουργικό μέρος του ML
- Χρειάζεται καλή αντίληψη του προβλήματος και ιδέες
- Trial and error

Why?

- Γιατί δεν αφήνουμε το μοντέλο να κάνει ότι θέλει με τα δεδομένα; Αφού (συνήθως) το feature engineering δεν προσθέτει πληροφορία
- Τα απλά μοντέλα δεν μπορούν
- Τα νευρωνικά?

Μπορούν...

Universal approximation theorem—Let $C(X, \mathbb{R}^m)$ denote the set of continuous functions from a subset X of a Euclidean $\mathbb{R}^n$ space to a Euclidean space $\mathbb{R}^m$. Let $\sigma \in C(\mathbb{R}, \mathbb{R})$. Note that $(\sigma \circ x)_i = \sigma(x_i)$, so $\sigma \circ x$ denotes σ applied to each component of x .

Then σ is not polynomial if and only if for every $n \in \mathbb{N}$, $m \in \mathbb{N}$, compact $K \subseteq \mathbb{R}^n$, $f \in C(K, \mathbb{R}^m)$, $\varepsilon > 0$ there exist $k \in \mathbb{N}$, $A \in \mathbb{R}^{k \times n}$, $b \in \mathbb{R}^k$, $C \in \mathbb{R}^{m \times k}$ such that

$$\sup_{x \in K} \|f(x) - g(x)\| < \varepsilon$$

where $g(x) = C \cdot (\sigma \circ (A \cdot x + b))$

Μπορούν...

Universal approximation theorem (*L1 distance, ReLU activation, arbitrary depth, minimal width*)—For any Bochner–Lebesgue p -integrable function $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ and any $\varepsilon > 0$, there exists a fully connected ReLU network F of width exactly $d_m = \max\{n + 1, m\}$, satisfying

$$\int_{\mathbb{R}^n} \|f(x) - F(x)\|^p \, dx < \varepsilon.$$

Moreover, there exists a function $f \in L^p(\mathbb{R}^n, \mathbb{R}^m)$ and some $\varepsilon > 0$, for which there is no fully connected ReLU network of width less than $d_m = \max\{n + 1, m\}$ satisfying the above approximation bound.

Αλλά...

- Θεωρητικά είναι ωραία guarantees αλλά δεν μας λένε:
 - Αν μπορεί κάποιος optimizer να βρει αυτό το νευρωνικό
 - Πόσο μεγάλο θα πρέπει να είναι το νευρωνικό
- Άρα πρέπει να διευκολύνουμε το νευρωνικό

Feature Engineering

- Θα ακολουθήσουμε αυτό:

https://introml.mit.edu/notes/feature_representation.html

Feature Engineering (Extra)

- Target Encoding
 - Αντικαθιστούμε κάθε κατηγορική τιμή με έναν αριθμό, ο οποίος αντιπροσωπεύει τη μέση τιμή του στόχου για αυτήν τη κατηγορία.
 - Smoothing:
$$\hat{x}_i = \frac{n_i \cdot \bar{y}_i + \alpha \cdot \bar{y}_{global}}{n_i + \alpha}$$
- PCA, θα το δούμε σε άλλο μάθημα

Ένθετο: Φυσική, Χημεία intuition

- Γιατί; Πολύ συχνό σε διαγωνισμούς (θα δούμε 2)
- Conservation Laws
- Invariances & Symmetries
 - π.χ temperature $> -273^{\circ}\text{C}$, clip it
 - Rotational and Translational Invariance $\Rightarrow$ ~~Absolute~~ relative positions
- Locality
- Energy Minimization

Questions?

Γρήγορες Ερωτήσεις Κατανόησης

- Features for (ανάλογα με την χρήση):
 - Κατοικίδιο (“dog”, “cat”, “snake”, “fish”)
 - “Very hot”, “hot”, “normal”, “cold”, “very cold”
 - “Green T-shirt”, “Blue shirt”, ...
 - Ταχύτητα → πρόβλεψη έντασης ήχου σύγκρουσης
 - x_1, x_2 όπου $e^{x_1} + e^{x_2}$ διατηρείται
 - Ταχυδρομικός κώδικας
 - has_ac (0 ή 1), summer_temp

Γρήγορες Ερωτήσεις Κατανόησης

- N data points με degree N polynomial features για regression, accuracy = ?
- 50 input features, degree 3 polynomial features. Τελικός αριθμός features = ?. Καλό;
- Feature $x \rightarrow \ln(x+1)$. Βοηθάει ένα decision tree;
- Πρόβλεψη ζήτησης ταξί. Data: hour_of_day (integer 0 to 23), minutes (integer 0 to 59)
 - Κάντε κάποιον μετασχηματισμό
 - Αν αυτό το δώσετε σε ένα γραμμικό μοντέλο, τι πρόβλημα υπάρχει;
 - Κάντε κάποιον μετασχηματισμό ξανά

Sine and Cosine transformation

Για περιοδικά/κυκλικά δεδομένα με περίοδο T

$$x_1' = \sin\left(\frac{2\pi x}{T}\right) \quad x_2' = \cos\left(\frac{2\pi x}{T}\right)$$

Γρήγορες Ερωτήσεις Κατανόησης

- Latitude & Longitude είναι καλά για τοποθεσία;
- Πρόβλεψη ισχύς σήματος για διάφορες τοποθεσίες. Έχετε x, y των κεραιών και x, y των πελατών
- Απόσταση πιτσαρίας από πελάτη για πρόβλεψη χρόνου παράδοσης, στο Manhattan.
- Κάποιος λέει αντί για one-hot encoding, να βάλουμε ένα learnable nn.Embedding πριν το πρώτο layer του νευρωνικού. Τι λέτε;

Questions?

Feature Engineering Theory: Done Break

Questions?

Example 1

NOAI China 2024 – Basketball Shooting

Example 1

Τι θα κάνουμε?

- Διαβάζουμε πολύ καλά την εκφώνηση


Νομίζω καταλάβατε ότι είναι σημαντικό!

Example 1

- Τα `shot_id` και `minutes_remaining` πρέπει να τα αφαιρέσουμε γιατί δεν υπάρχουν στο `test`. Να κάνουμε το ίδιο με το `shot_distance`;
- Βλέπουμε τα δεδομένα μας

```
fig, ax = plt.subplots(figsize=(4, 8))  
ax.scatter(data['loc_x'], data['loc_y'],  
c=data['shot_made_flag'], cmap='coolwarm', alpha=0.5, s=3)
```

Example 1



Example 1

- Το shot_distance μπορούμε να το φτιάξουμε εμείς για τα test data. Είναι και καλό feature;
Ναι
- Τι άλλα features θα μπορούσαμε να βάλουμε;
- Φαίνεται ένας διαχωρισμός στα σημεία μετά από μια απόσταση

Example 2

2^{ος} ΠΔΤΝ Πρόβλημα 3

Example 3

[https://www.bohrium.com/en/competitions/
25382276824?tab=introduce](https://www.bohrium.com/en/competitions/25382276824?tab=introduce)

Break

Past Competition Problems

MAIO 2025

https://github.com/jaredliw/ioai-tsp-2025/blob/main/maio-2025/maio_2025_letter_footprint.ipynb

NAIO Singapore 2025

<https://github.com/jaredliw/ioai-tsp-2025/blob/main/noai-singapore-2025/mental-health/mental-health.ipynb>

Romania 2025

<https://github.com/jaredliw/ioai-tsp-2025/blob/main/onia-romania-2025/oja/consum-caloric/consum-caloric.ipynb>

Romania 2025 - 2

<https://github.com/jaredliw/ioai-tsp-2025/blob/main/onia-romania-2025/oja/smartcargo/smartcargo.ipynb>